



UNIVERSITATEA
„ALEXANDRU IOAN CUZA”
din IAȘI



FEAA
FACULTATEA DE ECONOMIE
ȘI ADMINISTRAREA AFACERILOR

ALEXANDRU IOAN
CUZA UNIVERSITY
Faculty of Economics & Business
Administration

RAPPORT DE STAGE

Année Universitaire 2025 — 2026

Analyse Prédictive et Modélisation Statistique par Régression Logistique

Exploitation des données de l'Enquête Européenne sur la Santé (EHIS) 2019



06 AVRIL — 12 JUIN 2026

AUTEUR

Alexan Ravonneaux
BUT SD - 2ème année

TUTEUR ENSEIGNANT

M. Abdellah Qannari
Enseignant-chercheur universitaire

TUTEUR PROFESSIONNEL

M. Dănuț-Vasile Jemna
Enseignant-chercheur universitaire

RÉSUMÉ DES MISSIONS

L'objectif principal de ce stage était d'étudier les facteurs associés à l'absentéisme au travail à partir des données de l'enquête européenne EHIS 2019 (*European Health Interview Survey*).

Dans un premier temps, il a été nécessaire de comprendre la structure de la base de données ainsi que le contexte méthodologique de l'enquête EHIS 2019 afin d'identifier les variables disponibles et leur signification. Une revue de la littérature scientifique a ensuite été réalisée afin d'identifier les principaux déterminants de l'absentéisme au travail mis en évidence dans les études précédentes.

À partir de ces travaux, une phase de préparation des données a été menée. Celle-ci a consisté à sélectionner les variables pertinentes pour l'analyse, à traiter les valeurs manquantes et à recoder certaines variables afin de les rendre exploitables pour la modélisation statistique.

Enfin, une analyse des données a été réalisée à l'aide de techniques de visualisation afin d'étudier les relations entre les variables explicatives et l'absentéisme. Cette étape a été complétée par la construction et l'interprétation d'un modèle de régression logistique permettant d'identifier les facteurs les plus influents sur la probabilité d'arrêt maladie.

SUMMARY OF TASKS

The main objective of this internship was to examine the factors associated with absenteeism from work using data from the 2019 European Health Interview Survey (EHIS).

Initially, it was necessary to understand the structure of the database as well as the methodological context of the 2019 EHIS survey in order to identify the available variables and their meanings. A review of the scientific literature was then conducted to identify the main determinants of absenteeism at work highlighted in previous studies.

Based on this research, a data preparation phase was carried out. This involved selecting the variables relevant to the analysis, handling missing values, and recoding certain variables to make them suitable for statistical modeling.

Finally, an analysis of the data was performed using visualization techniques to examine the relationships between the explanatory variables and absenteeism. This step was followed by the construction and interpretation of a logistic regression model to identify the factors most influential on the probability of taking sick leave.

REMERCIEMENTS

Je tiens tout d'abord à adresser mes sincères remerciements à Monsieur Jemna, mon tuteur de stage, pour son accompagnement tout au long de cette expérience. Je le remercie particulièrement pour sa disponibilité, sa confiance et sa patience, qui m'ont permis de mener à bien mes missions dans les meilleures conditions. Ses conseils et son expertise ont été précieux tout particulièrement sur la création du modèle de régression logistique avec le langage R.

Je remercie également l'Université Alexandru Ioan Cuza ainsi que le Laboratoire d'Économie et de Statistique pour leur accueil et les excellentes conditions de travail qui m'ont été offertes durant ce stage. Cette immersion au sein d'un environnement de recherche international a constitué une expérience particulièrement enrichissante.

Je souhaite également exprimer ma gratitude à l'ensemble du corps enseignant de l'IUT, qui m'a accompagné tout au long de ma formation et m'a accordé sa confiance. Les connaissances et compétences acquises au cours de ces deux années de BUT Sciences des Données ont été essentielles à la réalisation de ce stage.

Enfin, je remercie la Région ainsi que les services administratifs en charge de la gestion de la bourse de mobilité. Leur soutien financier a rendu cette expérience à l'étranger possible. Sans cette aide, la réalisation de ce stage dans un contexte international n'aurait pas pu être envisagée dans les mêmes conditions.

À toutes les personnes ayant contribué, de près ou de loin, à la réussite de ce stage, j'adresse mes plus sincères remerciements.

SOMMAIRE

Résumé.....	2
Abstract.....	2
Remerciements.....	3
Sommaire.....	4
Introduction.....	5
1. Contexte et présentation de la structure d'accueil.....	6
1.1. Contexte national : la Roumanie, un pôle technologique en pleine ascension.....	6
1.2. Le contexte local : Iași, pôle dynamique et européen.....	7
1.3. L'Université Alexandru Ioan Cuza (UAIC).....	7
1.4. Le Laboratoire de recherche en économie et statistiques.....	8
2. L'enquête EHIS 2019.....	9
2.1. Contexte et objectifs de l'enquête EHIS.....	9
2.2. Méthodologie d'échantillonnage.....	9
2.3. Collecte des données et respect de la confidentialité.....	9
2.4. Structure du questionnaire.....	10
2.4.1. Structure détaillée du questionnaire.....	11
3. Causes de l'absentéisme.....	13
3.1. Quatre dimensions.....	13
4. Préparation de la base de données.....	15
4.1. Sélection des variables.....	15
4.2. Recodage des variables et gestion des valeurs manquantes.....	19
4.2.1. Variables socio-démographiques.....	19
4.2.2. État de santé.....	20
4.2.3. Déterminants de santé.....	21
4.2.4. Variable cible.....	22
5. Analyse.....	25
5.1. Analyses préalables.....	25
5.2. Plan de datavisualisation.....	25
5.2.1. Les résultats.....	26
5.3. Modélisation par régression logistique.....	26
6. Bilan.....	28
6.1. Difficultés rencontrées.....	28
6.2. Compétences acquises.....	28
6.3. Conclusion.....	28
Annexes.....	30
Annexe 1 : Code R, préparation de la base de données.....	30
Annexe 2 : Table de statistiques descriptives.....	33

Annexe 3 : Corrélogramme des variables explicatives.....	35
Annexe 4 : Répartition de l'impact de l'absentéisme par variable.....	36

INTRODUCTION

Dans un monde professionnel en constante mutation, la préservation de la santé au travail est devenue un enjeu majeur, tant pour le bien-être des individus que pour la performance des organisations. L'absentéisme pour raisons de santé représente non seulement un coût économique significatif, mais il est aussi le symptôme de conditions de travail parfois inadaptées. C'est dans ce contexte de santé publique et de statistiques appliquées que s'inscrit mon stage de deuxième année de BUT Sciences des Données, réalisé au sein de l'Université Alexandru Ioan Cuza (UAIC) à Iași, en Roumanie.

Affecté au laboratoire de recherche en économie et statistiques de la Faculté d'Économie et d'Administration des Affaires (FEAA), j'ai été chargé d'exploiter la troisième vague de l'Enquête Européenne sur la Santé (EHIS 2019). Cette base de données, riche de milliers d'observations à l'échelle européenne, permet d'étudier avec une grande finesse les comportements de santé et les facteurs de risques environnementaux et professionnels.


La mission qui m'a été confiée consiste à identifier et à modéliser les facteurs qui influencent la probabilité d'absence au travail pour raisons de santé. Pour répondre à cette problématique, le choix s'est porté sur la variable d'intérêt **AW1** (« Absent from work due to personal health problems in the past 12 months »), qui constitue un indicateur direct de l'impact de la santé sur l'activité professionnelle.

L'objectif central de ce travail est de mesurer dans quelle mesure l'effort physique ressenti au travail, capturé par la variable **PE1** (« Physical effort of working tasks »), augmente le risque de recours à l'arrêt maladie. Pour isoler cet effet et obtenir des résultats statistiquement robustes, j'ai mis en œuvre une modélisation par **régression logistique**. Cette méthode permet non seulement de prédire la probabilité d'absence, mais surtout de quantifier le poids spécifique des contraintes physiques par rapport à d'autres déterminants socio-démographiques ou médicaux.

Ce rapport détaille ainsi la démarche suivie, de la phase critique de préparation et de nettoyage des données EHIS jusqu'à l'interprétation des résultats du modèle, en passant par l'analyse descriptive des populations concernées.

1. CONTEXTE ET PRÉSENTATION DE LA STRUCTURE D'ACCUEIL

1.1. Contexte national : la Roumanie, un pôle technologique en pleine ascension



Située au carrefour de l'Europe centrale, orientale et balkanique, la Roumanie est une république membre de l'Union européenne depuis 2007 et de l'OTAN. Au-delà de son riche héritage culturel marqué par ses racines latines uniques dans la région, le pays s'est imposé en deux décennies comme l'un des moteurs économiques les plus dynamiques d'Europe de l'Est.

Cette croissance est portée par un secteur technologique en pleine effervescence, souvent qualifié de « Silicon Valley de l'Europe orientale ». Bénéficiant d'une des infrastructures numériques les plus performantes au monde, notamment en termes de vitesse de connexion internet, la Roumanie a su attirer de nombreux centres de recherche et entreprises internationales de pointe.

Ce dynamisme est soutenu par un système universitaire d'excellence qui forme une main-d'œuvre hautement qualifiée dans les domaines de l'ingénierie et de l'analyse de données. C'est dans cet environnement tourné vers l'innovation et le développement scientifique que se situe làsi, pôle académique historique et stratégique du pays.

1.2. Le contexte local : Iași, pôle dynamique et européen

Iași, située dans le nord-est de la Roumanie, est la deuxième ville la plus peuplée du pays avec plus de 316 000 habitants en 2026.

Elle est située à la frontière de la région de la Moldavie où elle a été la capitale entre 1564 et 1859. Iași a également été la capitale de la Roumanie entre 1916 et 1918. Au-delà de son riche patrimoine culturel et religieux, Iași est surtout reconnue comme un centre universitaire et économique majeur. Plus de 60 000 étudiants y fréquentent les universités de la ville dont l'université Alexandru Ioan Cuza, l'une des plus prestigieuses du pays, qui m'a accueilli pour ce stage.



1.3. L'Université Alexandru Ioan Cuza (UAIC)

Fondée en 1860, l'Université Alexandru Ioan Cuza (UAIC) est la plus ancienne institution d'enseignement supérieur de Roumanie. Forte de son prestige historique, elle accueille aujourd'hui environ 24 000 étudiants. L'UAIC se distingue par sa pluridisciplinarité, étant organisée en 15 facultés qui couvrent un large spectre allant des sciences exactes



aux sciences humaines. Cette organisation en départements permet de favoriser la gestion des ressources et d'encourager les projets de recherche croisant différentes disciplines. Par exemple, ce stage permettra potentiellement au département des sciences sociales d'explorer de nouvelles perspectives analytiques.

1.4. Le Laboratoire de recherche en économie et statistiques

Au sein de l'UAIC, j'ai été affecté à la Faculté d'Économie et d'Administration des Affaires (FEAA), et plus précisément au sein de son laboratoire de recherche en économie et statistiques.



Le laboratoire se consacre au développement de modèles économétriques et statistiques appliqués aux dynamiques socio-économiques, à la production d'analyses fondées sur la donnée pour l'aide à la décision, ainsi qu'au rayonnement de la recherche académique via des publications internationales.

L'environnement y est très propice à l'apprentissage technique : les chercheurs utilisent quotidiennement la modélisation statistique pour traiter de grandes bases de données.

2. L'ENQUÊTE EHIS 2019

2.1. Contexte et objectifs de l'enquête EHIS

L'état de santé des Européens étant l'une des principales préoccupations des États membres de l'Union européenne, La Direction de l'information et de la recherche en santé (DHIR) mène depuis 2002 l'enquête européenne sur la santé (*European Health Interview Survey*, EHIS), elle est déployée tous les 5 à 6 ans. Elle vise à fournir un état des lieux précis de la santé des populations européennes qu'aucune autre enquête ne peut identifier à ce jour. Ces données sont exclusivement réservées à des fins d'analyses et ne sont pas publiques. Son objectif principal est de recueillir des données harmonisées sur l'état de santé des populations, leurs recours aux soins, leurs déterminants de santé ainsi que leurs caractéristiques socio-démographiques.

2.2. Méthodologie d'échantillonnage

Afin de garantir une représentativité statistique optimale la population cible de l'enquête se compose d'individus âgés de 15 ans et plus résidant dans des ménages privés, ce qui exclut les individus vivant en institutions collectives (telles que les hôpitaux et les maisons de retraite). Pour constituer cet échantillon, l'Institut National de Statistique a procédé à un tirage aléatoire stratifié, segmenté selon l'âge, le sexe et le milieu de résidence des répondants.

Comparée à un échantillonnage aléatoire simple, où l'échantillon serait totalement aléatoire, cette stratification permet d'obtenir un échantillon représentatif de la population européenne selon les différences d'âges de sexes et de milieux de résidence. Elle aide également à réduire significativement la variance des estimateurs et surtout à s'assurer que les sous populations, même minoritaires, sont représentées proportionnellement à leur taille.

Pour la régression logistique, il est indispensable d'avoir un échantillon représentatif de la population pour affirmer des conclusions à l'échelle de la population européenne.

2.3. Collecte des données et respect de la confidentialité

Les résultats de l'enquête EHIS de 2019 ont été majoritairement collectés par un entretien en face-à-face assisté par un ordinateur (CAPI) pour enregistrer directement les réponses du participant sur une tablette, un téléphone ou un ordinateur portable. Le cas échéant, l'entretien était assisté par papier (PAPI). Il était également possible de compléter ses réponses avec un entretien téléphonique assisté par ordinateur (CATI). La collecte des données était censée être effectuée uniquement par les méthodes CAPI et

PAPI, cependant, en raison de l'épidémie de COVID-19, les enquêtes menées en mars et avril 2020 ont été réalisées par CATI. Des mesures de contrôle de qualité ont été mise en place par l'Institut National de la Statistiques (INS) afin de garantir la qualité des données de l'enquête.

Certaines questions plus sensibles pour les répondants pouvaient faire l'objet d'un auto-questionnaire strictement confidentiel pour limiter les biais de désirabilité sociale.

Toutes les données ont été recueillies de manière strictement confidentielle et anonyme, après l'obtention du consentement des participants. Pour les participants de moins de 18 ans, les consentements écrit de leurs tuteurs légaux ont été recueillis au préalable.

Les données de santé étant par nature extrêmement sensibles, la base EHIS est soumise à des règles d'anonymisation drastiques pour se conformer au Règlement Général sur la Protection des Données (RGPD). Parmi les techniques employées pour empêcher toute réidentification des répondants, on retrouve la **suppression de variables d'identification directes**, telles que les unités d'échantillonnage primaires ou la langue de l'entretien. Par ailleurs, toutes les variables sensibles sont **regroupées par classes**, ainsi l'âge, le revenus ou le nombre de nuits passés à l'hôpital, par exemple, ne peuvent révéler un individu. Le **plafonnement, ou « top coding »**, est également utilisé pour regrouper les âges très avancés au sein d'une seule modalité ou limiter la taille déclarée des ménages. Enfin, une **généralisation par recodage** est appliquée aux secteurs d'activité afin de fondre les professions spécifiques dans de grandes catégories génériques, protégeant ainsi le secret statistique.

2.4. Structure du questionnaire

Pour garantir la comparabilité des réponses d'un pays à l'autre, l'enquête repose sur un principe de standardisation des intrants. Tous les États participants utilisent un questionnaire de base identique, composé d'une centaine de questions, rigoureusement traduit et articulé autour de **quatre modules fondamentaux**. Le premier module rassemble **les variables socio-démographiques**, comme l'âge, le sexe, le niveau d'éducation et le statut d'emploi. Le deuxième module évalue **l'état de santé** perçu en recensant les maladies chroniques, les limitations de la vie quotidienne et la santé mentale. Le troisième se concentre sur **le recours aux soins**, incluant l'utilisation des services médicaux, la médecine préventive et la consommation de médicaments. Enfin, le dernier module aborde **les déterminants de la santé liés au mode de vie**, tels que l'indice de masse corporelle, les habitudes alimentaires, le niveau d'activité physique et les addictions.

2.4.1. structure détaillée du questionnaire

Ci-dessous la structure détaillée des questions de l'enquête EHIS 2019 avec les informations que chaque partie vise à saisir :

- ❖ **VARIABLES TECHNIQUES DE L'ENQUÊTE** : Capture les informations nécessaires au suivi de la qualité des données, à la gestion du terrain, aux méthodes de collecte (ex : face-à-face, web).
- ❖ **VARIABLES SOCIO-DÉMOGRAPHIQUES** : Capture le profil démographique et socio-économique du répondant (âge, sexe, éducation, emploi, revenu, composition du ménage).
- ❖ **VARIABLES DE SANTÉ** :
 - **État de santé** : Capture la perception subjective de la santé globale, les problèmes durables et le bien-être.
 - **Maladies et affections chroniques** : Capture la prévalence des diagnostics médicaux spécifiques (diabète, asthme, hypertension, etc.) sur les 12 derniers mois.
 - **Accidents et blessures** : Capture l'occurrence d'accidents (route, domicile, loisirs) et la nécessité de soins associés.
 - **Absence du travail** : Capture l'impact des problèmes de santé sur la productivité et la vie professionnelle.
 - **Limitations fonctionnelles** : Capture les difficultés sensorielles (vue, ouïe) ou motrices dans la vie quotidienne.
 - **Activités de soins personnels** : Capture l'autonomie du répondant dans les actes essentiels (manger, se laver, s'habiller).
 - **Activités domestiques** : Capture les capacités à gérer les tâches ménagères et administratives courantes.
 - **Douleur** : Capture l'intensité des douleurs physiques et leur impact sur le fonctionnement normal.
 - **Santé mentale** : Capture l'état psychologique (dépression, anxiété, énergie) sur les deux dernières semaines.
- ❖ **SOINS DE SANTÉ** :
 - **Recours aux soins hospitaliers et de jour** : Capture l'utilisation des structures hospitalières.
 - **Recours aux soins ambulatoires et à domicile** : Capture les visites chez le médecin, le dentiste ou l'utilisation de services à domicile.

- **Utilisation de médicaments** : Capture la consommation de produits pharmaceutiques (avec ou sans ordonnance).
- **Services préventifs** : Capture les comportements de prévention (dépistages, vaccins, bilans de santé).
- **Besoins non satisfaits en matière de soins de santé** : Capture les barrières financières, géographiques ou administratives à l'accès aux soins.

❖ **DÉTERMINANTS DE LA SANTÉ :**

- **Indice de masse corporelle et taille** : Capture la corpulence et les indicateurs morphologiques.
- **Activité physique** : Capture le niveau de dépense énergétique (travail, transport, sport, renforcement musculaire).
- **Habitudes alimentaires** : Capture la fréquence et la qualité de la consommation (fruits, légumes, boissons sucrées).
- **Tabagisme** : Capture les comportements liés au tabac, le vapotage et l'exposition au tabagisme passif.
- **Consommation d'alcool** : Capture les habitudes de consommation et les risques liés aux excès.
- **Soutien social** : Capture le réseau de proximité disponible en cas de problèmes personnels.
- **Fourniture de soins ou d'assistance informels** : Capture l'implication bénévole du répondant dans l'aide à des personnes dépendantes.

3. DIFFÉRENTES CAUSES DE L'ABSENTÉISME

Mon analyse va se diriger vers les causes de l'absentéisme au travail, ce phénomène a un impact à la fois sur la qualité de vie des individus et sur la productivité des organisations.

Dans le cadre de l'enquête EHIS 2019, l'absentéisme peut être défini comme l'absence temporaire d'un individu de son activité professionnelle en raison de problèmes de santé. Cette variable correspond à l'intitulé : "Absent from work due to personal health problems in the past 12 months", en français : "Absent au travail pour des problèmes de santé personnelle au cours des 12 derniers mois". Cette question n'est réservée qu'aux employés et ses modalités de réponses sont : "oui", "non", "non précisé" et "sans objet".

3.1. Quatre dimensions

L'enquête européenne de santé EHIS 2019 (European Health Interview Survey) est structurée autour de 4 sous-parties : les variables socio-démographiques, l'état de santé, le recours aux soins et les déterminants de la santé liés au mode de vie. Chacune de ces dimensions peut exercer une influence directe ou indirecte sur l'absentéisme au travail. Il m'a donc été pertinent d'étudier au préalable les études existantes sur ce sujet afin de déterminer les principaux facteurs à risque et ainsi guider ma problématique.

Les variables sociodémographiques : le taux d'absentéisme chez les femmes est en moyenne de 5,19 % contre 3,60 % chez les hommes [1]. Ce taux atteint 6,54 % chez les ouvriers, tandis qu'il n'est que de 2,36 % chez les cadres [1]. Les personnes employées de moins de 30 ans présentent un taux d'absentéisme de 3,26 % contre 5,68 % pour les travailleurs âgés de 60 ans et plus [1].

L'état de santé : La maladie constitue la première cause d'arrêt de travail et représente 90,94 % de toutes les absences [1]. Les pathologies psychologiques représentent la première cause d'arrêts de travail de longue durée, constituant 44 % des arrêts indemnissables [2]. Parmi les actifs déclarant au moins trois maladies chroniques, 30 % ont indiqué avoir connu une interruption d'activité de plus de six mois pour raisons de santé [3]. À l'échelle nationale, les lombalgies représentent en effet 20 % des accidents du travail et sont responsables de la perte de plus de 12,2 millions de journées de travail chaque année [7].

Les recours aux soins : Les arrêts de travail couplés à une hospitalisation sont en moyenne deux fois plus longs que les arrêts de travail sans hospitalisation [4]. Les maladies professionnelles, nécessitant des parcours de soins complexes, engendrent les arrêts les plus longs avec une durée moyenne de 121,73 jours par arrêt [1].

Les déterminants de la santé liés au mode de vie : L'obésité augmente significativement la probabilité de maladie, engendrant en France 607 millions d'euros de pertes de production annuelles dues aux seuls arrêts de travail des personnes obèses [5]. La sédentarité concerne 68,3 % des travailleurs, qui ne respectent pas la recommandation de 150 minutes d'activité physique par semaine. Ce facteur est directement corrélé à l'augmentation des problèmes de santé et de l'absentéisme de longue durée [6]. En outre, les contraintes biomécaniques constituent un facteur prédictif critique. Les troubles musculo-squelettiques (TMS) représentent aujourd'hui plus de 87 % des maladies professionnelles reconnues [8].

Références :

- [1] Groupe APICIL, Observatoire des arrêts de travail, 2025 `
- [2] WTW, Baromètre de l'absentéisme et des arrêts de travail longs, 2025
- [3] DREES, Études et Résultats : Les interruptions d'activité pour raisons de santé, 2005
- [4] Verlingue, Baromètre Absentéisme, 2025
- [5] Asterès, Les effets de l'obésité sur le monde du travail : emploi et absentéisme, 2025
- [6] IDEWE, Rapport de santé au travail sur l'activité physique et la sédentarité, 2026
- [7] Assurance Maladie - Risques professionnels, L'essentiel sur la santé et la sécurité au travail (Données sur la lombalgie), 2025
- [8] INRS, Statistiques sur les maladies professionnelles et les troubles musculo-squelettiques liés à l'effort physique, 2025

Afin de modéliser efficacement la probabilité d'un arrêt de travail, la littérature suggère d'isoler les principales variables explicatives parmi les différentes dimensions. Sur le plan sociodémographique, le **sexe**, l'**âge** et la **catégorie socioprofessionnelle** s'imposent comme prédicteurs majeurs de l'absentéisme. Concernant l'état de santé et le recours aux soins, la déclaration de **maladies chroniques** et l'existence d'une **hospitalisation** récente sont les covariables les plus déterminantes pour anticiper les arrêts fréquents ou prolongés. Enfin, les indicateurs de mode de vie mesurables dans l'enquête, notamment l'**indice de masse corporelle (obésité)** et le **niveau d'activité physique**, constituent des facteurs de risque aggravants essentiels à inclure dans la régression logistique.

4. PREPARATION DE LA BASE DE DONNEES

4.1 Sélection des variables

Avant de réaliser la régression logistique, j'ai sélectionné les variables à garder pour réduire la dimensionnalité du jeu de données afin d'optimiser les performances de notre modèle de régression logistique.

Voici les variables conservées avant le recodage pour la modélisation :

Variable cible

Variable	Description	Modalités	Pertinence
AW1	Absent from work due to personal health problems in the past 12 months	1: Yes 2 : No -1: Not stated -2 : Not applicable	Variable cible.

Variables sociodémographiques

Variable	Description	Modalités	Pertinence
SEX	Sex of respondent	1: Male 2 : Female	Les femmes présentent en moyenne un taux plus élevé que les hommes (5,19 % contre 3,60 %).
AGE	Age of respondent in completed years at the time of the interview	15-17 18-19 20-24 25-29 30-34 35-39 40-44 45-49 50-54	Le taux d'absentéisme croît avec l'âge, passant de 3,26 % pour les moins de 30 ans à 5,68 % pour les plus de 60 ans.

		55-59 60-64 65-69 70-74 75-79 80-84 85 et plus	
JOBISCO	Occupation in main job	1 2 3 4 5 6 7 8 9 0	Le taux d'absentéisme atteint 6,54 % chez les ouvriers, tandis qu'il n'est que de 2,36 % chez les cadres.
HHINCOME	Net monthly equivalized income of the household	1: Below 1st quintile 2 : Between 1st and 2nd quintile 3 : Between 2nd and 3rd quintile 4 : Between 3rd and 4th quintile 5 : Between 4th and 5th quintile -1: Not stated	Indicateur de la précarité socio-économique et indicateur proxy indirect de la CSP. Les catégories professionnelles moins favorisées comme les ouvriers ont des taux d'absentéisme plus élevés.

État de santé

Variable	Description	Modalités	Pertinence
CD1H	Having a low back disorder or other chronic back defect in the past 12 months	1 : Yes 2 : No -1 : Not stated	Les lombalgies représentent 20 % des accidents du travail.

CD10	Having depression in the past 12 months	1: Yes 2: No -1: Not stated	Les pathologies psychologiques constituent la première cause des arrêts de travail de longue durée (44 % des arrêts indemnisés).
BMI	Body mass index	1: Underweight 2: Normal weight 3: Pre-obese 4: Obese -1: Not stated -3: Proxy	L'obésité est un facteur de risque majeur qui augmente significativement la probabilité d'arrêt maladie.

Les déterminants de la santé

Variable	Description	Modalités	Pertinence
PE1	Physical effort of working tasks (both paid and unpaid work activities included)	1 : Mostly sitting or standing 2 : Mostly walking or tasks of moderate physical effort 3 : Mostly heavy labour or physically demanding work 4 : Not performing any working tasks -1 : Not stated	87% des maladies professionnelles reconnues son dus aux troubles musculo-squelettiques (TMS)

		-3 : Proxy	
PE7	Time spent on doing sports, fitness or recreational (leisure) physical activities in a typical week	HHMM (hours/minutes) 1 : Not stated -2 : not applicable -3 : Proxy	La sédentarité est directement corrélée à l'apparition de troubles physiques (TMS) et à une augmentation de l'absentéisme de longue durée.
SK1	Type of tobacco smoking behaviour	1: Daily smoking 2 : Occasional smoking 3: No smoking -1: Not stated	Le tabagisme est un comportement à risque reconnu qui favorise le développement de maladies chroniques (respiratoires, cardiovasculaires) conduisant à des arrêts maladie.

Afin d'exploiter au mieux la base de données EHIS, une phase de préparation et de nettoyage des données a été réalisée avec le langage R.

La base de données EHIS 2019 (European Health Interview Survey) contenait initialement **14 192 observations** et **151 variables** pour la population française.

Ci-dessous un extrait de la base de données :

PID	HHID	WGT	WGT_SPEC	PROXY	REFDATE	INTMETHOD	SEX	AGE	COUNTRY	REGION	BIRTHPLACE	CITIZEN	BIRTHPLACEFATH	BIRTHPLACEMOTH	DEG_URB	HATLEVEL	MAINSTAT	FT_PT	
27428	27428	1773,398	1773,398	1	201910	21	2	35-39	FR	-1	10	10	10	10	10	2	5	10	2
27437	27437	1435,981	1435,981	1	201909	31	2	35-39	FR	-1	10	10	10	10	10	1	6	10	1
27439	27439	2048,31	2048,31	1	201909	31	2	30-34	FR	-1	10	10	10	10	10	1	3	10	1
27541	27541	1964,207	1964,207	1	201910	31	2	35-39	FR	-1	10	10	10	10	10	1	3	10	2
27565	27565	1400,554	1400,554	1	201909	21	2	40-44	FR	-1	21	10	21	21	2	6	10	2	
27577	27577	1701,164	1701,164	1	201909	31	2	30-34	FR	-1	22	22	22	22	2	6	10	1	
27582	27582	1758,828	1758,828	1	201909	31	2	20-24	FR	-1	22	10	22	22	2	3	10	2	
27591	27591	1355,315	1355,315	1	201909	31	2	30-34	FR	-1	10	10	10	10	21	1	8	10	1
27469	27469	1493,288	1493,288	1	201910	21	1	35-39	FR	-1	10	10	10	10	10	1	6	10	1
27489	27489	1819,752	1819,752	1	201910	31	2	25-29	FR	-1	22	22	22	22	1	6	10	1	
27493	27493	2029,682	2029,682	1	201910	21	1	45-49	FR	-1	10	10	10	10	10	1	5	10	1
27357	27357	2692,075	2692,075	1	201909	21	2	30-34	FR	-1	10	10	22	22	1	2	10	2	
27	27	2776,79	2776,79	1	201906	31	2	30-34	FR	-1	10	10	10	10	21	1	7	10	1
28	28	2831,047	2831,047	1	201905	31	1	40-44	FR	-1	10	10	10	10	10	1	7	10	1
37	37	2766,29	2766,29	1	201906	31	1	40-44	FR	-1	10	10	22	22	1	7	10	1	
38	38	2806,017	2806,017	1	201905	31	2	55-59	FR	-1	10	10	10	10	10	1	8	10	2
45	45	2839,633	2839,633	1	201906	31	1	35-39	FR	-1	10	10	10	10	10	1	7	10	1
48	48	2851,076	2851,076	1	201907	31	2	60-64	FR	-1	10	10	10	10	10	1	6	10	2
54	54	5950,921	5950,921	1	201907	21	2	25-29	FR	-1	10	10	10	10	10	1	7	10	1
153	153	6407,063	6407,063	1	201906	21	2	30-34	FR	-1	21	21	21	21	1	7	10	1	
163	163	4308,599	4308,599	1	201905	31	1	30-34	FR	-1	22	22	22	22	1	7	10	1	
177	177	4877,323	4877,323	1	201905	21	1	60-64	FR	-1	10	10	10	10	10	1	2	10	1
190	190	4555,054	4555,054	1	201907	21	1	45-49	FR	-1	10	10	10	10	10	1	7	10	1
195	195	3150,84	3150,84	1	201905	31	1	25-29	FR	-1	10	10	10	10	10	1	7	10	1
202	202	7700,897	7700,897	1	201911	21	2	45-49	FR	-1	22	22	22	22	1	0	10	2	
351	351	3885,904	3885,904	1	201907	31	2	35-39	FR	-1	10	21	21	21	21	1	7	10	1
357	357	3940,096	3940,096	1	201904	31	1	60-64	FR	-1	10	10	21	10	1	5	10	1	
358	358	2560,968	2560,968	1	201906	31	1	50-54	FR	-1	10	10	10	10	10	1	7	10	1
373	373	4598,923	4598,923	1	201907	21	2	65-69	FR	-1	22	10	22	22	1	8	10	-1	
391	391	2523,805	2523,805	1	201905	31	1	50-54	FR	-1	10	10	10	10	22	1	7	10	-1
393	393	2907,879	2907,879	1	201906	31	2	40-44	FR	-1	10	10	10	10	10	1	7	10	1
215	215	4729,138	4729,138	1	202001	21	2	25-29	FR	-1	10	10	10	10	1	7	10	1	
216	216	4580,952	4580,952	1	201910	21	1	40-44	FR	-1	10	10	22	22	1	7	10	1	
234	234	2952,67	2952,67	1	201907	31	2	30-34	FR	-1	22	10	22	22	1	7	10	1	
247	247	2602,157	2602,157	1	201907	31	1	55-59	FR	-1	21	10	21	21	1	7	10	1	

L'objectif de cette étude étant d'analyser les déterminants de l'arrêt maladie chez les individus en activité professionnelle, un filtrage a été effectué afin de ne conserver que les personnes actives occupées. Ce filtrage repose sur la variable MAINSTAT, qui correspond au statut principal de l'individu. La modalité 10 désigne les personnes ayant un emploi au moment de l'enquête. Le filtrage a été réalisé à l'aide du code R suivant :

```
filter(MAINSTAT == 10)
```

Par ailleurs, seules les variables jugées pertinentes pour l'analyse ont été conservées avec cet extrait du code :

```
select(SEX, AGE, MAINSTAT, JOBISCO, HHINCOME, CD1H, CD10, BMI,  
       SK1, PE1, PE7, AW1)
```

Une fois la population d'étude définie, plusieurs traitements ont été réalisés afin de préparer les données à la modélisation logistique

4.2 Recodage des variables et gestion des valeurs manquantes

Plusieurs variables ont été recodées afin de rendre leurs modalités plus compréhensibles et adaptées à l'interprétation statistique. Les libellés numériques d'origine ont ainsi été transformés en textes explicites et les nombres ont été catégorisés en classe selon les résultats trouvés de la littérature.

Dans la base EHIS 2019, certaines modalités étaient codées par les valeurs -1, -2 et -3. Ces codes correspondent à des données manquantes, des refus de réponse ou des réponses inconnues. Afin d'éviter des erreurs lors des traitements statistiques, ces lignes ont été supprimés pour un nettoyage optimal.

4.2.1 Variables socio-démographiques

La variable définissant le **sexe** du répondant (SEX) a été recodée en deux modalités :

- 1 → « Homme »
- 2 → « Femme »

La **tranche d'âge** du répondant (AGE) présentait 16 modalités que j'ai réduites en trois modalités :

- AGE < 30 → « Moins de 30 ans »
- 30 > AGE < 60 → « Entre 30 et 60 ans »
- 60 < AGE → « Plus de 60 ans »

Les catégories socio-professionnelles (JOBISCO) ont été regroupées afin de diminuer le nombre de modalités :

- 1 (« *Directeurs et cadres de direction* ») → « Poste à responsabilité intellectuel »
- 2 (« *Professions intellectuelles et scientifiques* ») → « Poste à responsabilité intellectuel »
- 3 (« *Professions intermédiaires* ») → « Poste à responsabilité intellectuel »
- 4 (« *Employés de type administratif* ») → « Poste intellectuel »
- 5 (« *Personnel des services et vendeurs* ») → « Poste intellectuel »
- 6 (« *Agriculteurs et ouvriers qualifiés* ») → « Poste à responsabilité manuel »
- 7 (« *Métiers de l'artisanat* ») → « Poste manuel »
- 8 (« *Conducteurs d'installations et machines* ») → « Poste intellectuel »
- 9 (« *Professions élémentaires* ») → « Poste intellectuel »
- 0 (« *Professions militaires* ») → « Poste militaire »

Les lignes dont la valeur est -1 ou -2 ont été supprimées.

Le niveau de revenu du ménage (HHINCOME) a été réparti en quintiles explicites :

- 1 → « 1er quintile (Le plus bas) »
- 2 → « 2ème quintile »
- 3 → « 3ème quintile »
- 4 → « 4ème quintile »
- 5 → « 5ème quintile (Le plus haut) »

Les lignes dont la valeur est -1 ou -3 ont été supprimées.

4.2.2 État de santé

La variable déterminant si le répondant a subi **des problèmes de dos** au cours des 12 derniers mois (CD1H) a été recodée en deux modalités :

- 1 → « Problème de dos »
- 2 → « Pas de problème de dos »

Les lignes dont la valeur est -1 ont été supprimées.

La variable qui détermine si le répondant est, ou a été, **en dépression** dans les 12 derniers mois (CD10) a été recodée selon deux modalités :

- 1 → « a subi une dépression »
- 2 → « pas de dépression »

Les lignes dont la valeur est -1 ont été supprimées.

L'IMC (BMI) a été regroupé selon les catégories de l'Organisation mondiale de la santé (OMS) :

- < 18.5 → « Insuffisance pondérale »
- >= 18.5 & BMI < 25 → « Corpulence normale »
- >= 25 & BMI < 30 → « Surpoids »
- >= 30 → « Obésité »

Les lignes dont la valeur est -1 ou -3 ont été supprimées.

4.2.3 Déterminants de santé

Le comportement tabagique (SK1) a été recodée en deux catégories :

- Fumeur quotidien ; Fumeur occasionnel → « Fumeur »
 - Non-fumeur → « Non-fumeur »
-

L'intensité de l'effort physique au travail (PE1) a été regroupées en deux modalités :

- 1 ; 4 → « Pas d'effort physique au travail remarquable »
- 2 ; 3 → « Effort physique remarquable »

Les lignes dont la valeur est -1 ou -3 ont été supprimées.

Le temps d'activités physique exercée par semaine (PE7) a été regroupée en deux classes :

- < 150 → « Moins de 2h30 »
 - > 150 → « 2h30 ou plus »
 - NA → « Pas de sport »
-

4.2.4 Variable cible

La variable cible AW1, correspondant à **la présence d'un arrêt maladie**, a été recodée de la manière suivante :

- 1 → « 1 »
- 2 → « 0 »

1 signifiant « oui » et 2 signifiant « non »

Les lignes dont la valeur est -1 ou -2 ont été supprimées.

En conclusion, cette phase de préparation des données a permis d'obtenir une base de données structurée et adaptée à l'étude de l'absentéisme. La nouvelle base de données est constituée de **6905 observations** sur **11 variables**.

Voici ci-dessous les variables recodifiées :

Variable cible

Variable	Nouvelles modalités	Explication
AW1 (arrêt de travail)	- « 1 » - « 0 »	

Variables sociodémographiques

Variable	Nouvelles modalités	Explication
SEX (sexe du répondant)	- « Homme » - « Femme »	
AGE (tranche d'âge du répondant)	- « Moins de 30 ans » - « Entre 30 et 60 ans » - « Plus de 60 ans »	La littérature montre que le taux d'absentéisme passe de 3,26 % pour les moins de 30 ans à 5,68 % pour les plus de 60 ans.
JOBISCO (catégories socio-professionnelles)	- « Poste à responsabilité intellectuel »	J'ai estimé qu'un poste à responsabilité est moins propice à recourir aux arrêts de travail.

	- « Poste à responsabilité manuel » - « Poste intellectuel » - « Poste manuel » - « Poste militaire »	J'ai déterminé la responsabilité de chaque poste grâce aux croisements de cette variable avec le revenu du ménage. Par ailleurs, j'ai intégré les métiers d'agriculteur et d'ouvrier qualifié aux postes à responsabilité car leur salaire dépend en majorité de leur travail.
HHINCOME (niveau de revenu du ménage)	- « 1er quintile (Le plus bas) » - « 2ème quintile » - « 3ème quintile » - « 4ème quintile » - « 5ème quintile (Le plus haut) »	Après une datavisualisation sur l'impact du recours à l'arrêt de travail sur le niveau de revenu du ménage, il apparaît que chaque niveau a son impact et que diminuer la granularité ferait perdre de l'information.

État de santé

Variable	Nouvelles modalités	Explication
CD1H (problème de dos)	- « Problème de dos » - « Pas de problème de dos »	
CD1O (dépression)	- « A subi(e) une dépression » - « Pas de dépression »	
BMI (IMC)	- « Insuffisance pondérale » - « Corpulence normale » - « Surpoids » - « Obésité »	< 18.5 → « Insuffisance pondérale » >= 18.5 & BMI < 25 → « Corpulence normale » >= 25 & BMI < 30 → « Surpoids » >= 30 → « Obésité »

Les déterminants de la santé

Variable	Nouvelles modalités	Explication
SK1 (Fumeur)	- « Fumeur » - « Non-fumeur »	Fumeur quotidien et occasionnel regroupé en « fumeur »
PE1 (effort physique au travail)	- « Pas d'effort physique au travail remarquable » - « Effort physique remarquable »	« Principalement assis ou debout » et « Aucune activité professionnelle » regroupés en « Pas d'effort physique au travail remarquable » « Principalement en marchant ou effectuant des tâches d'effort physique modéré » et « Principalement des travaux pénibles ou physiquement exigeants » regroupés en « Effort physique remarquable »
PE7 (Activité physique hebdomadaire)	- « Moins de 2h30 » - « 2h30 ou plus »	La sédentarité concerne 68,3 % des travailleurs, qui ne respectent pas la recommandation de 150 minutes d'activité physique par semaine.

5. ANALYSE

5.1 Analyses préalables

À la suite du nettoyage il était opportun d'analyser la base de données afin d'en avoir une image concrète.

Premièrement je rappelle que sur ces 11 variables et 6905 observations, toutes les valeurs manquantes ont été supprimées pour ne pas biaiser l'apprentissage du futur modèle. Pour avoir une vue directe de la base de données, j'ai développé une table de statistiques descriptives tenant compte de la variable cible (annexe 2).

J'ai voulu vérifier qu'il n'y ait pas de multicollinéarité, ce qui pourrait compromettre le modèle. Pour cela j'ai calculé le V de Cramer pour chaque paire de variables explicatives et j'ai affiché cela sous forme de **corrélogramme** avec la fonction ggcorrplot de la librairie ggplot2 (annexe 3). La corrélation la plus forte est entre l'effort physique au travail et la catégorie socio professionnelle en ayant un résultat de 0.31, n'étant pas excessif j'ai décidé de ne rien changer.

Afin de visualiser la répartition de l'absentéisme selon les différentes modalités des variables étudiées, plusieurs graphiques descriptifs ont été réalisés (annexe 2).

Pour identifier les variables potentiellement associées à l'absentéisme, un test du χ^2 d'indépendance a également été réalisé entre la variable cible et chaque variable explicative qualitative.

Les résultats montrent que la majorité des variables étudiées présentent une association statistiquement significative avec l'absentéisme (p -value < 0,05). Les liens les plus marqués concernent les variables **Dépression** (V de Cramer = 0,161) et **Problème de dos** (V de Cramer = 0,137), qui présentent des effets de taille modérée. Les autres variables significatives, telles que le sexe, la catégorie socioprofessionnelle, le revenu du ménage, l'IMC, le tabagisme ou encore l'activité physique, présentent des effets faibles mais non négligeables. Seule la variable **Effort physique au travail** n'apparaît pas significativement liée à l'absentéisme au seuil de 5 % ($p = 0,058$).

5.2 Plan de datavisualisation

Afin d'élaborer une datavisualisation pertinente, je me suis appuyé sur mes résultats et graphiques précédents.

Ma datavisualisation est divisée en plusieurs tableaux de bord classés hiérarchiquement de la vue d'ensemble à l'analyse prédictive afin d'en tirer le plus d'information.

1. Les indicateurs clés :

- Effectif total de la population étudiée
- Taux d'absentéisme dans toute la population
- Graphique en anneau : Répartition de l'absentéisme

2. Le corrélogramme :

- Corrélogramme (annexe 3)

3. Les graphiques d'impact de l'absentéisme :

- Répartition de l'impact de l'absentéisme sur chaque modalité par variables (annexe 4)

5.2.1 Les résultats

Les résultats de ces analyses m'ont montré que **la dépression** et **les problèmes de dos** sont les deux variables les plus significatives en termes de dispersion des effectifs, cependant le tableau des statistiques descriptives m'a révélé que la répartition de leurs effectifs n'était pas équilibrée, ce qui diminuera leur efficacité pour le modèle. Il n'y a pas de corrélation majeure entre les variables explicatives.

5.3 Modélisation par régression logistique

Afin d'identifier les facteurs influençant la probabilité d'un arrêt maladie, un modèle de régression logistique binaire a été construit. Cette méthode est particulièrement adaptée lorsque la variable à expliquer est qualitative et binaire, comme c'est le cas ici avec la variable *Arrêt_Maladie* (oui/non).

L'interprétation des résultats repose sur les *Odds Ratios* (OR). Un OR supérieur à 1 indique une augmentation de la probabilité d'être en arrêt maladie par rapport à la modalité de référence, tandis qu'un OR inférieur à 1 traduit une diminution de cette probabilité.

Les résultats montrent que plusieurs variables sont significativement associées à l'absentéisme. La variable ayant l'effet le plus important est **la dépression**. Les individus ayant subi une dépression présentent une probabilité d'arrêt maladie environ 3,16 fois plus élevée que ceux n'en ayant pas subi (OR = 3,16 ; $p < 0,001$). De même, les personnes déclarant des **problèmes de dos** ont un risque d'arrêt maladie 1,70 fois plus élevé (OR = 1,70 ; $p < 0,001$).

Les caractéristiques socioprofessionnelles apparaissent également comme des facteurs déterminants. Comparativement à la catégorie de référence, les individus occupant un poste manuel présentent une probabilité d'arrêt maladie multipliée par 2,31 (OR = 2,31 ;

$p < 0,001$), tandis que les postes intellectuels et les postes à responsabilité intellectuelle affichent respectivement des Odds Ratios de 2,13 et 1,94. À l'inverse, la catégorie militaire n'est pas significativement associée à l'absentéisme ($p = 0,313$).

Concernant les caractéristiques individuelles, les femmes présentent une probabilité d'arrêt maladie plus élevée que les hommes ($OR = 1,29$; $p < 0,001$). Les individus âgés de moins de 30 ans sont également davantage concernés par les arrêts maladie que la catégorie de référence ($OR = 1,46$; $p = 0,006$), alors que la tranche d'âge comprise entre 30 et 60 ans n'est pas significative.

L'état de santé et les habitudes de vie influencent également la probabilité d'absence. Les personnes en insuffisance pondérale présentent un risque supérieur d'arrêt maladie ($OR = 1,63$; $p = 0,001$), tout comme les personnes en situation d'obésité ($OR = 1,19$; $p = 0,035$). Le tabagisme ($OR = 1,17$; $p = 0,007$) et une activité physique hebdomadaire inférieure à 2 h 30 ($OR = 1,15$; $p = 0,037$) sont également associés à une augmentation du risque d'arrêt maladie.

En revanche, certaines variables ne présentent pas d'effet statistiquement significatif dans le modèle, notamment l'effort physique au travail ($p = 0,362$), plusieurs catégories de revenus ainsi que certaines modalités de l'âge et de l'IMC. Ces résultats suggèrent que leur influence est limitée une fois les autres facteurs pris en compte.

Enfin, le modèle met néanmoins en évidence plusieurs déterminants significatifs de l'absentéisme et permet d'identifier les profils les plus exposés au risque d'arrêt maladie.

6. BILAN

6.1 Difficultés rencontrées

Au cours de ce stage, plusieurs difficultés ont été rencontrées. La principale concernait l'utilisation de l'anglais dans un contexte professionnel. En effet, les échanges avec M. JEMNA ainsi que la compréhension des consignes et des missions nécessitaient une bonne maîtrise de la langue. Cette situation a parfois rendu la communication plus complexe, notamment lors des premières semaines du stage.

La rédaction du présent rapport a également constitué un défi important. Il a été nécessaire de structurer les différentes étapes du projet, de synthétiser les analyses réalisées et de présenter les résultats de manière claire et rigoureuse.

Malgré ces difficultés, les différents obstacles rencontrés ont progressivement été surmontés grâce à la pratique, aux échanges avec les encadrants et à un travail personnel régulier.

6.2 Compétences acquises

Ce stage a été particulièrement enrichissant tant sur le plan professionnel que personnel. D'un point de vue technique, il m'a permis d'approfondir mes connaissances du langage R, notamment dans les domaines du nettoyage de données, de l'analyse statistique et de la modélisation. J'ai également développé une meilleure maîtrise des méthodes d'analyse de données et de leur interprétation.

Sur le plan rédactionnel, la réalisation du rapport ainsi que la communication des résultats obtenus ont contribué à améliorer mes capacités d'expression écrite. Par ailleurs, l'utilisation quotidienne de l'anglais dans un environnement professionnel m'a permis de gagner en aisance, aussi bien à l'oral qu'à l'écrit.

Enfin, cette expérience a favorisé mon développement personnel. Travailler au sein d'un environnement international m'a permis de découvrir différentes cultures et méthodes de travail, renforçant ainsi mon ouverture d'esprit et ma capacité d'adaptation. Ce stage a également contribué à développer ma maturité professionnelle en m'amenant à travailler de manière plus autonome, à gérer mes responsabilités et à m'intégrer dans une équipe de travail.

6.3 Conclusion

Ce stage au sein du Laboratoire d'Économie et de Statistique de l'Université Alexandru Ioan Cuza a constitué une expérience particulièrement enrichissante, tant sur le plan académique que personnel. Il m'a permis de mettre en pratique les connaissances acquises au cours de ma formation en BUT Sciences des Données dans le cadre d'un projet concret portant sur l'étude des facteurs associés à l'absentéisme au travail.

Au-delà des compétences techniques développées, cette expérience a également contribué à renforcer mon autonomie, ma capacité d'adaptation et mon aisance dans un environnement international. Travailler dans un contexte anglophone et multiculturel m'a permis de développer de nouvelles compétences relationnelles et professionnelles qui constitueront un atout pour la poursuite de mes études et de ma future carrière.

Ce stage confirme mon intérêt pour l'analyse de données et la modélisation statistique. Il représente une étape importante dans mon parcours de formation et m'a permis de mieux appréhender les exigences du monde professionnel ainsi que les applications concrètes des sciences des données dans le domaine de la recherche.

ANNEXE

Annexe 1 : Code R, préparation de la base de données

```
# Chargement des packages
library(tidyverse)

# 1. Chargement de la base avec le bon séparateur (;) et le marqueur décimal
(.)
df <- read_delim("FR_Anonymisation.csv", delim = ";", locale =
  locale(decimal_mark = "."), show_col_types = FALSE)

# 2. Nettoyage et recodage
df_clean <- df %>%
  # Sélection des variables strictement nécessaires pour le modèle
  select(SEX, AGE, MAINSTAT, JOBISCO, HHINCOME, CD1H, CD10, BMI, SK1, PE1,
  PE7, AW1) %>%

  # Filtrage exclusif des actifs occupés
  filter(MAINSTAT == 10) %>%

  # 3. SUPPRESSION DES LIGNES (Gestion des codes d'anonymisation / non-
  réponse)
  filter(
    (is.na(JOBISCO) | !(JOBISCO %in% c(-1, -2))),
    (is.na(HHINCOME) | HHINCOME != -1),
    (is.na(BMI) | !(BMI %in% c(-1, -3))),
    (is.na(PE1) | !(PE1 %in% c(-1, -3))),
    (is.na(CD1H) | CD1H != -1),
    (is.na(CD10) | CD10 != -1),
    (is.na(AW1) | !(AW1 %in% c(-1, -2)))
  ) %>%

  # 4. RECODAGE ET CRÉATION DES MODALITÉS TEXTUELLES
  mutate(
    # Sexe
    Sexe = case_when(
      SEX == 1 ~ "Homme",
      SEX == 2 ~ "Femme",
      TRUE ~ NA_character_
    ),

    # Tranches d'âge
    Tranche_Age = case_when(
      AGE %in% c("15-17", "18-19", "20-24", "25-29") ~ "Moins de 30 ans",
      AGE %in% c("30-34", "35-39", "40-44", "45-49", "50-54", "55-59") ~
      "Entre 30 et 60 ans",
      AGE %in% c("60-64", "65-69", "70-74", "75-79", "80-84", "85+") ~ "Plus
      de 60 ans",
      TRUE ~ NA_character_
    )
  )
```

```

),

# Catégories socio-professionnelles regroupées
Categorie_Socioprofessionnelle = case_when(
  JOBISCO %in% c(1, 2, 3) ~ "Poste à responsabilité intellectuel",
  JOBISCO %in% c(4, 5, 8, 9) ~ "Poste intellectuel",
  JOBISCO == 6 ~ "Poste à responsabilité manuel",
  JOBISCO == 7 ~ "Poste manuel",
  JOBISCO == 0 ~ "Poste militaire",
  TRUE ~ NA_character_
),

# Quintiles de revenus
Revenu_Menage_Quintiles = case_when(
  HHINCOME == 1 ~ "1er quintile (Le plus bas)",
  HHINCOME == 2 ~ "2ème quintile",
  HHINCOME == 3 ~ "3ème quintile",
  HHINCOME == 4 ~ "4ème quintile",
  HHINCOME == 5 ~ "5ème quintile (Le plus haut)",
  TRUE ~ NA_character_
),

# 4.2.2 État de santé
Probleme_Dos = case_when(
  CD1H == 1 ~ "Problème de dos",
  CD1H == 2 ~ "Pas de problème de dos",
  TRUE ~ NA_character_
),

Depression = case_when(
  CD10 == 1 ~ "a subi une dépression",
  CD10 == 2 ~ "pas de dépression",
  TRUE ~ NA_character_
),

Classe_IMC = case_when(
  BMI < 18.5 ~ "Insuffisance pondérale",
  BMI >= 18.5 & BMI < 25 ~ "Corpulence normale",
  BMI >= 25 & BMI < 30 ~ "Surpoids",
  BMI >= 30 ~ "Obésité",
  TRUE ~ NA_character_
),

# 4.2.3 Déterminants de santé
Habitue_Tabac = case_when(
  SK1 %in% c(1, 2) ~ "Fumeur",
  SK1 == 3 ~ "Non-fumeur",
  TRUE ~ NA_character_
),

Effort_Physique_Travail = case_when(

```

```

    PE1 %in% c(1, 4) ~ "Pas d'effort physique au travail remarquable",
    PE1 %in% c(2, 3) ~ "Effort physique remarquable",
    TRUE ~ NA_character_
  ),

  # Activité physique (Conversion HHMM en minutes)
  PE7_Num = as.numeric(PE7),
  PE7_Minutes = (PE7_Num %/% 100) * 60 + (PE7_Num %% 100),

  Activite_Physique_Semaine = case_when(
    PE7_Num %in% c(-1, -2, -3) | is.na(PE7_Num) ~ "Pas de sport",
    PE7_Minutes < 150 ~ "Moins de 2h30",
    PE7_Minutes >= 150 ~ "2h30 ou plus",
    TRUE ~ NA_character_
  ),

  # 4.2.4 Variable cible
  Arret_Maladie = case_when(
    AW1 == 1 ~ "Oui",
    AW1 == 2 ~ "Non",
    TRUE ~ NA_character_
  )
) %>%

# 5. SÉLECTION FINALE
select(Sexe, Tranche_Age, Categorie_Socioprofessionnelle,
       Revenu_Menage_Quintiles,
       Probleme_Dos, Depression, Classe_IMC, Habitude_Tabac,
       Effort_Physique_Travail, Activite_Physique_Semaine, Arret_Maladie)
%>%

# 6. NETTOYAGE DES NA RESTANTS
mutate(across(everything(), as.character)) %>%
mutate(across(everything(), ~ replace_na(., "")))

# Sauvegarde du dataset prêt pour la régression logistique
write_excel_csv2(df_clean, "FR_Anonymisation_Regression.csv")


```

Annexe 2 : table de statistiques descriptives

Characteristic	Arrêt Maladie (0 = Non, 1 = Oui)			p-value ²
	Overall N = 6,905 ¹	0 N = 4,757 ¹	1 N = 2,148 ¹	
Sexe				<0.001
Femme	3,431 (50%)	2,254 (47%)	1,177 (55%)	
Homme	3,474 (50%)	2,503 (53%)	971 (45%)	
Tranche_Age				0.042
Entre 30 et 60 ans	5,425 (79%)	3,734 (78%)	1,691 (79%)	
Moins de 30 ans	1,089 (16%)	733 (15%)	356 (17%)	
Plus de 60 ans	391 (5.7%)	290 (6.1%)	101 (4.7%)	
Categorie_Socioprofessionnelle				<0.001
Poste à responsabilité intellectuel	3,395 (49%)	2,419 (51%)	976 (45%)	
Poste à responsabilité manuel	200 (2.9%)	165 (3.5%)	35 (1.6%)	
Poste intellectuel	2,748 (40%)	1,795 (38%)	953 (44%)	
Poste manuel	507 (7.3%)	335 (7.0%)	172 (8.0%)	
Poste militaire	55 (0.8%)	43 (0.9%)	12 (0.6%)	
Revenu_Menage_Quintiles				<0.001
1er quintile (Le plus bas)	977 (14%)	694 (15%)	283 (13%)	
2ème quintile	1,401 (20%)	906 (19%)	495 (23%)	
3ème quintile	1,506 (22%)	1,002 (21%)	504 (23%)	
4ème quintile	1,547 (22%)	1,089 (23%)	458 (21%)	
5ème quintile (Le plus haut)	1,474 (21%)	1,066 (22%)	408 (19%)	

Probleme_Dos				<0.001
Pas de problème de dos	4,633 (67%)	3,398 (71%)	1,235 (57%)	
Problème de dos	2,272 (33%)	1,359 (29%)	913 (43%)	
Depression				<0.001
a subi une dépression	397 (5.7%)	154 (3.2%)	243 (11%)	
pas de dépression	6,508 (94%)	4,603 (97%)	1,905 (89%)	
Classe_IMC				<0.001
Corpulence normale	3,646 (53%)	2,576 (54%)	1,070 (50%)	
Insuffisance pondérale	215 (3.1%)	121 (2.5%)	94 (4.4%)	
Obésité	906 (13%)	590 (12%)	316 (15%)	
Surpoids	2,138 (31%)	1,470 (31%)	668 (31%)	
Habitude_Tabac				<0.001
Fumeur	1,984 (29%)	1,292 (27%)	692 (32%)	
Non-fumeur	4,921 (71%)	3,465 (73%)	1,456 (68%)	
Effort_Physique_Travail				0.061
Effort physique remarquable au travail	3,570 (52%)	2,423 (51%)	1,147 (53%)	
Pas d'effort physique au travail remarquable	3,335 (48%)	2,334 (49%)	1,001 (47%)	
Activite_Physique_Semaine				<0.001
2h30 ou plus	1,630 (24%)	1,191 (25%)	439 (20%)	
Moins de 2h30	5,275 (76%)	3,566 (75%)	1,709 (80%)	
¹ n (%)				
² Pearson's Chi-squared test				

Annexe 3 : Corrélogramme des variables explicatives



Annexe 4 : Répartition de l'impact de l'absentéisme sur chaque modalité par variable

Impact de l'absentéisme selon les caractéristiques individuelles

Proportion d'arrêts maladie par modalité

